


Algorithms 实质上都是在解 KKT 条件. 讨论几种典型的算法.

无约束优化 / 有约束优化

强调: ① 所有优化算法都是迭代算法.

② $x^{k+1} = x^k + \alpha^k d^k$ (k 时刻的方向, 与 x 的维数相同) α^k : 步长、标量 举例: 下山法




$$\alpha^k = \arg \min_{\alpha \geq 0} f_0(x^k + \alpha d^k) \quad \text{一维凸问题.}$$

③ 解步长的方法: line search

一般讨论的是下降的算法.

(1) 迭代算法: 黄金分割法 (优选法)



折半查找的思想

0.618 是收敛速度最快的.

(2) Armijo Rule (还可以的步长)


$$\text{if } f_0(x^k + \alpha d^k) > f(x^k) + \underbrace{\gamma \alpha \nabla f_0^T(x^k) d^k}_{\text{取}(0, 0.5)}$$

$$\text{then, } \alpha \leftarrow \alpha \cdot \beta_{\Delta(0,1)}$$

设成 0.5, 收敛性的证明会很漂亮

otherwise, stop.

Backtracking





$$\text{Taylor: } f_0(x^k) + \alpha \nabla f_0^T(x^k) d^k$$

$\min f(x)$, $f(x)$ 一阶可微, 最优性条件 $\nabla f(x) = 0$, 假设能找到 x , $\nabla f(x) \approx 0$.

$x \rightarrow x^*$? $f(x) \rightarrow f(x^*)$?

假设 $f(x)$ 二阶可微, 且有 强凸性.

$$\exists m > 0, \forall x \in \text{dom} f, \nabla^2 f(x) \geq mI$$



(直观解释: 每一点都不能特别平)

强凸的好处: $\forall x, y \in \text{dom} f, f(y) \geq f(x) + \nabla f^T(x)(y-x) + \frac{1}{2}m\|y-x\|_2^2$

I. $\nabla f(x) \rightarrow 0, f(x) \rightarrow f(x^*)$?

x 给定, $f(x) + \nabla f^T(x)(y-x) + \frac{1}{2}m\|y-x\|_2^2$ 是 y 的凸函数. 仿射项 + 二次项

一阶偏导 $\nabla f(x) + m(\hat{y}-x) = 0, \hat{y} = x - \frac{\nabla f(x)}{m}$, 代入上式.

原式 $\geq f(x) - \frac{1}{2m}\|\nabla f(x)\|_2^2$,

进而 $f(y) \geq f(x) + \nabla f^T(x)(y-x) + \frac{1}{2}m\|y-x\|_2^2 \geq f(x) - \frac{1}{2m}\|\nabla f(x)\|_2^2$ for $\forall x, \forall y$

取 y 为最优解, $p^* \geq f(x) - \frac{1}{2m}\|\nabla f(x)\|_2^2$, i.e. $p^* + \frac{1}{2m}\|\nabla f(x)\|_2^2 \geq f(x) \geq p^*$

则有 $\|f(x) - p^*\|_2 \leq \frac{1}{2m}\|\nabla f(x)\|_2^2$


II. $\nabla f(x) \rightarrow 0, x \rightarrow x^*$?

$p^* = f(x^*) \geq f(x) + \nabla f^T(x)(x^*-x) + \frac{m}{2}\|x^*-x\|_2^2$ 没有二次项, 则想办法改写.


回忆 Cauchy-Schwarz inequality, $\langle a, b \rangle + \|a\|_2\|b\|_2 \geq 0$

then $f(x) \geq p^* \geq f(x) - \|\nabla f(x)\|_2\|x^*-x\|_2 + \frac{m}{2}\|x^*-x\|_2^2$

$-\|\nabla f(x)\|_2\|x^*-x\|_2 + \frac{m}{2}\|x^*-x\|_2^2 \leq 0$, i.e. $\|x^*-x\|_2 \leq \frac{2}{m}\|\nabla f(x)\|_2$



(最优值很近, 但是最优解很远)



可量化的损失

(最优值和最优解都更近了)

凸性不要太强, 规定上界: $\exists M > 0, \forall x \in \text{dom} f, \nabla^2 f(x) \leq M I$ 曲线不能太陡

从正定的角度规定上界和下界

$\forall x, y \in \text{dom} f, f(y) \leq f(x) + \nabla f^T(x)(y-x) + \frac{M}{2}\|y-x\|_2^2$

(不强凸性)

重要结论: $p^* \leq f(x) - \frac{1}{2M}\|\nabla f(x)\|_2^2$

1. 梯度下降法. (负梯度方向, $\partial^k = -\nabla f(x^k)$)


Repeat $\partial^k = \operatorname{argmin} f(x^k + \partial d^k)$

exact or inexact


$$\partial_{\max} \geq \partial \geq 0$$

$$x^{k+1} = x^k + \partial^k d^k$$

Until Convergence



梯度: 函数值增加方向 $\nabla f(x^0)$



• 分析算法收敛性: $\forall x \in \operatorname{dom} f, \mu I \preceq \nabla^2 f(x) \preceq M I$

1) exact line search

$$\tilde{f}(\partial) = f(x^k + \partial d^k) = f'(x^k - \partial \nabla f(x^k))$$

$$\tilde{f}(x^{k+1}) \leq f(x^k) + \nabla f^T(x^k)(-\partial \nabla f(x^k)) + \frac{M}{2} \|\partial \nabla f(x^k)\|_2^2$$

$$\Leftrightarrow \tilde{f}(\partial) \leq f(x^k) - \partial \|\nabla f(x^k)\|_2^2 + \frac{M\partial^2}{2} \|\nabla f(x^k)\|_2^2$$

$$-\partial \|\nabla f(x^k)\|_2^2 + M\partial \|\nabla f(x^k)\|_2^2 = 0, \Rightarrow \partial = \frac{1}{M}$$

$$\min_{\partial} \tilde{f}(\partial) \leq f(x^k) - \frac{1}{M} \|\nabla f(x^k)\|_2^2 + \frac{1}{2M} \|\nabla f(x^k)\|_2^2$$

$$f(x^{k+1}) \leq f(x^k) - \frac{1}{2M} \|\nabla f(x^k)\|_2^2 - p^*$$

$$\text{另外 - 个不等式: } p^* \geq f(x^k) - \frac{1}{2M} \|\nabla f(x^k)\|_2^2$$

$$\text{结论: } \frac{1}{2M} \|\nabla f(x^k)\|_2^2 + f(x^{k+1}) - p^* \leq f(x^k) - p^*$$

$$-\frac{1}{2M} \|\nabla f(x^k)\|_2^2 + f(x^{k+1}) - p^* \leq 0$$

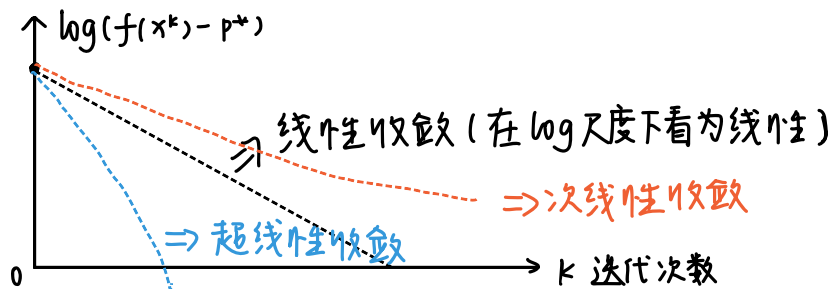
$$\text{进而, } M(f(x^{k+1}) - p^*) + m(f(x^k) - p^*) \leq M(f(x^k) - p^*)$$

$$\Leftrightarrow (f(x^{k+1}) - p^*) \leq (1 - \frac{m}{M})(f(x^k) - p^*) \quad \text{说明每一步离最优解越来越近}$$

$$\text{given } \varepsilon, \text{ when } \left\| \frac{f(x^{k+2}) - p^*}{f(x^k) - p^*} \right\| \leq \varepsilon$$

$$\text{i.e. } \left\| \frac{f(x^{k+1}) - p^*}{f(x^k) - p^*} \right\| \leq \left\| 1 - \frac{m}{M} \right\| \Rightarrow (1 - \frac{m}{M})^\tau = \varepsilon \Rightarrow \tau = \frac{\log \varepsilon}{\log(1 - \frac{m}{M})} \Rightarrow \text{用 } \frac{m}{M} \text{ 近似}$$

用收敛曲线解释:



2) Inexact Line Search (Armijo Rule)

当 $0 \leq \alpha \leq \frac{1}{M}$ 时, 迭代必然停止. - $\gamma \alpha \|\nabla f(x^k)\|_2^2$

$\hat{f}(\alpha) = f(x^{k+1}) \leq f(x^k) + \gamma \alpha \nabla f^T(x^k) \alpha^k$ 时接受 α .

当 $0 \leq \alpha \leq \frac{1}{M}$, 必有 $(-\alpha + \frac{M\alpha^2}{2}) \leq -\frac{\alpha}{2}$

$$\begin{aligned} \hat{f}(\alpha) = f(x^{k+1}) &\leq f(x^k) - \alpha \|\nabla f(x^k)\|_2^2 + \frac{M\alpha^2}{2} \|\nabla f(x^k)\|_2^2 \\ &\leq f(x^k) - \frac{\alpha}{2} \|\nabla f(x^k)\|_2^2 \end{aligned}$$

不可能特别小


$\alpha_{\text{inexact}} = \alpha_{\text{max}}$ 或 $\geq \frac{\beta}{M}$

$$f(x^{k+1}) = \hat{f}(\alpha_{\text{exact}}) \leq f(x^k) - \frac{1}{2M} \|\nabla f(x^k)\|_2^2$$

$$f(x^{k+1}) \leq f(x) - \min\{\gamma \alpha_{\text{max}}, \frac{\gamma \beta}{M}\} \|\nabla f(x)\|_2^2$$

$$\frac{f(x^{k+1}) - p^*}{f(x^k) - p^*} \leq 1 - \min\left\{2m\gamma\alpha_{\text{max}}, \frac{2m\gamma\beta}{M}\right\} \in [0, 1]$$

∴ 仍然是线性收敛.



斜率不同, 收敛速度不同.

13. $f(x) = x^T P x$, $P \in S_+^n$

$$\nabla^2 f(x) = P$$

最大特征值

最小特征值.

$$M I \geq P \geq m I$$

$$\frac{M}{m}$$

病态矩阵 $\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ 梯度下降法收敛速度不会特别快

Zig-zag:

